

PHÂN TÍCH CẢM XÚC THEO KHÍA CẠNH HOTEL (ABSA HOTEL)

Đỗ Minh Dũng¹, Huỳnh Diên Thực², Phạm Trần Xuân Tiên³, Trần Minh Vũ⁴,

GVHD: Huỳnh Văn Tín

¹23520326, ²23521555, ³23521583, ⁴23521819,

Abstract

Phân tích cảm xúc theo khía cạnh (Aspect-Based Sentiment Analysis - ABSA) đóng vai trò then chốt trong việc hiểu sâu sắc trải nghiệm khách hàng. Trong nghiên cứu này, chúng tôi tập trung vào việc giải quyết bài toán ABSA cho lĩnh vực khách sạn (Hotel domain) bằng tiếng Việt. Chúng tôi trình bày quy trình xây dựng bộ dữ liệu từ nền tảng TripAdvisor với quy trình gán nhãn nghiêm ngặt đạt độ đồng thuận Inter-Annotator Agreement (IAA) (Kontonatsios et al., 2023) là 0.9551 (F1-score). Nghiên cứu tiến hành đánh giá thực nghiệm các phương pháp từ học máy truyền thống đến các mô hình ngôn ngữ tiên huấn luyện. Kết quả cho thấy mô hình PhoBERT đạt hiệu suất vượt trội với F1-score 73.83% trên tập kiểm thử, cung cấp một nền tảng vững chắc cho các ứng dụng thực tiễn trong ngành du lịch.

1 Introduction

Sự phát triển mạnh mẽ của các nền tảng du lịch trực tuyến trong những năm gần đây đã dẫn đến sự gia tăng đột biến về lượng đánh giá (review) của khách hàng về trải nghiệm lưu trú. Việc phân tích thủ công nguồn dữ liệu khổng lồ này là bất khả thi, đặt ra nhu cầu cấp thiết về việc áp dụng các kỹ thuật Phân tích cảm xúc (Sentiment Analysis) để tự động xác định thái độ của khách hàng, từ đó hỗ trợ việc đánh giá và nâng cao chất lượng dịch vụ.

Các cách tiếp cận truyền thống trong phân tích cảm xúc thường gán một nhãn cảm xúc duy nhất (Positive, Neutral, Negative) cho toàn bộ văn bản review. Mặc dù phương pháp này có ưu điểm là đơn giản, dễ triển khai và phù hợp cho các bài toán đánh giá tổng quan, chúng tồn tại những hạn chế đáng kể. Thực tế cho thấy, một đánh giá của khách hàng thường đề cập đến nhiều khía cạnh khác nhau của dịch vụ, và mỗi khía cạnh có thể mang những sắc thái cảm xúc trái ngược nhau. Việc chỉ sử dụng một nhãn tổng thể không thể biểu diễn đầy đủ thông tin, làm mất đi các cảm xúc chi tiết theo từng khía

cạnh. Hệ quả là các khách sạn gặp khó khăn trong việc xác định chính xác yếu tố nào đang làm hài lòng khách hàng hoặc cần được cải thiện.

Để giải quyết vấn đề này, Phân tích cảm xúc theo khía cạnh (Aspect-Based Sentiment Analysis - ABSA) được sử dụng nhằm hiểu chính xác trải nghiệm khách hàng theo từng khía cạnh cụ thể. Trong nghiên cứu này, mục tiêu của chúng tôi là ứng dụng ABSA cho miền dữ liệu đánh giá khách sạn (hotel domain). Cụ thể, các đóng góp chính bao gồm:

- Thu thập và xây dựng bộ dữ liệu review về khách sạn.
- Thực hiện phân tích cảm xúc theo từng khía cạnh cụ thể.
- Đánh giá hiệu quả của các phương pháp khác nhau, bao gồm các thuật toán Machine Learning truyền thống (Logistic Regression, SVM, MultinomialNB, Random Forest) và mô hình Deep Learning (PhoBERT).

2 Data construction

2.1 Data Collection

Bộ dữ liệu được thu thập từ TripAdvisor, một nền tảng du lịch trực tuyến phổ biến. Để đảm bảo tính súc tích và tập trung của các phản hồi, chúng tôi chỉ tiến hành thu thập các bài đánh giá (review) có độ dài dưới 100 từ.

2.2 Annotation Schema

Đối với mỗi bài đánh giá khách sạn, mục tiêu gán nhãn là xác định hai thành phần chính: **Danh mục khía cạnh (Aspect Category)** và **Cực tính cảm xúc (Sentiment Polarity)**. Một bài đánh giá có thể đề cập đến nhiều khía cạnh, và mỗi khía cạnh sẽ gắn liền với một cảm xúc riêng biệt. Đầu ra cuối cùng được biểu diễn dưới dạng tập hợp các cặp:

$$Output = \{(Aspect, Sentiment)\}$$

Định nghĩa Khía cạnh (Aspect) Một khía cạnh được định nghĩa là sự kết hợp giữa một thực thể (Entity) và một thuộc tính (Attribute), ký hiệu là Entity#Attribute.

Các **Thực thể (Entities)** đại diện cho các đối tượng chính trong trải nghiệm khách sạn, bao gồm:

- HOTEL: Khách sạn nói chung.
- ROOMS: Phòng ở.
- ROOM_AMENITIES: Tiện nghi trong phòng.
- FACILITIES: Tiện ích chung (hồ bơi, gym...).
- SERVICE: Thái độ và chất lượng phục vụ.
- LOCATION: Vị trí khách sạn.
- FOOD&DRINKS: Dịch vụ ăn uống.

Các **Thuộc tính (Attributes)** mô tả các đặc điểm cụ thể của thực thể: GENERAL (chung), PRICES (giá cả), DESIGN&FEATURES (thiết kế & tính năng), CLEANLINESS (vệ sinh), COMFORT (tiện nghi), QUALITY (chất lượng), STYLE&OPTIONS (phong cách & lựa chọn), và MISCELLANEOUS (khác).

Tuy nhiên, không phải thuộc tính nào cũng áp dụng cho mọi thực thể. Chúng tôi xây dựng một ma trận ràng buộc để xác định các cặp Entity-Attribute hợp lệ như Bảng 1.

Entity / Attribute	GENERAL	PRICES	DESIGN&FEATURES	CLEANLINESS	COMFORT	QUALITY	STYLE&OPTIONS	MISCELLANEOUS
HOTEL	✓	✓	✓	✓	✓	✓	×	✓
ROOMS	✓	✓	✓	✓	✓	✓	×	✓
ROOM_AMENITIES	✓	✓	✓	✓	✓	✓	×	✓
FACILITIES	✓	✓	✓	✓	✓	✓	×	✓
SERVICE	✓	×	×	×	×	×	×	×
LOCATION	✓	×	×	×	×	×	×	×
FOOD&DRINKS	×	✓	×	×	×	✓	✓	✓

Table 1: Constraint matrix of Entity-Attribute pairs valid for the annotation schema.

Cực tính Cảm xúc (Sentiment Polarity) Mỗi khía cạnh được xác định sẽ được gán một trong ba nhãn cảm xúc:

- **Positive:** Thể hiện sự hài lòng hoặc lời khen.
- **Negative:** Thể hiện sự không hài lòng hoặc lời chê.
- **Neutral:** Thông tin trung lập hoặc không rõ cảm xúc.

Ví dụ:

Review: “Khách sạn giá rẻ, gần biển. Nhân viên lễ tân thiếu lịch sự.”

Labels:

- HOTEL#PRICES → Positive
- LOCATION#GENERAL → Positive
- SERVICE#GENERAL → Negative

2.3 Annotation Process

Quy trình gán nhãn dữ liệu trải qua hai giai đoạn, được minh họa bởi Figure 1 và Figure 3:




Figure 1: Quy trình huấn luyện Annotators.




Figure 2: Kết quả độ đồng thuận IAA.

Giai đoạn huấn luyện Annotators: trải qua 3 vòng để đảm bảo độ chính xác và thống nhất giữa các Annotator. Tại mỗi vòng, độ đồng thuận Inter-Annotator Agreement (IAA) được tính toán để đánh giá chất lượng. Kết quả IAA trung bình




Figure 3: Quy trình gán nhãn chính thức.

tăng dần qua các vòng: Round 1 (0.7226), Round 2 (0.9097), và đạt mức cao nhất ở Round 3 (0.9551).

Giai đoạn gán nhãn chính thức: bao gồm việc giải quyết các nhãn mâu thuẫn thông qua thảo luận và biểu quyết để tạo ra bộ dữ liệu cuối cùng.

2.4 Data Statistics

Bộ dữ liệu cuối cùng bao gồm tổng cộng 2389 reviews, được mô tả chi tiết trong bảng Table 2

Dataset	No. Rev.	No. Asp.	Len.	Vocab	*
Train	1658	7109	54	5994	-
Val	359	1558	58	2558	689
Test	372	1597	56	2722	796
Full	2389	10624	55	7413	-

Table 2: Thống kê chi tiết dữ liệu. **Note:** *: số từ xuất hiện trong tập Test/Val nhưng không có trong Train.




Figure 4: Phân bố của các khía cạnh.

Phân bố dữ liệu cho thấy sự mất cân bằng giữa các nhãn, với các khía cạnh phổ biến nhất là SERVICE#GENERAL (91.3%), HOTEL#GENERAL (64.7%), và FOOD&DRINKS#QUALITY (61.2%).

Về mặt cảm xúc, nhãn Positive chiếm đa số áp đảo so với Negative và Neutral trong bộ dữ liệu.

3 Preprocessing

Dữ liệu đánh giá thu thập từ các nền tảng trực tuyến như TripAdvisor thường mang đặc điểm phi cấu trúc và chứa nhiều nhiễu. Các đánh giá này thường được viết theo văn phong tự do, không tuân thủ




Figure 5: Phân bố của các khía cạnh.

nghiêm ngặt các quy tắc chính tả, và chứa nhiều thành phần phi ngôn ngữ như biểu tượng cảm xúc (emoji), ký tự đặc biệt, hoặc ngôn ngữ mạng (teen-code). Những yếu tố nhiễu này ảnh hưởng tiêu cực đến khả năng trích xuất đặc trưng và hiệu suất của các mô hình học máy. Do đó, việc xây dựng một quy trình tiền xử lý dữ liệu chặt chẽ là bước thiết yếu để làm sạch và chuẩn hóa dữ liệu đầu vào.

Quy trình tiền xử lý được mô tả chi tiết trong Hình 6.




Figure 6: Quy trình tiền xử lý dữ liệu

Chuẩn hóa bảng mã và âm sắc. Do đặc thù tiếng Việt có nhiều bảng mã và cách đặt dấu khác nhau, toàn bộ dữ liệu được quy đổi về định dạng Unicode chuẩn nhằm tránh hiện tượng cùng một từ nhưng có nhiều định danh máy tính khác nhau. Đồng thời, các biến thể về vị trí đặt dấu thanh (ví dụ: “hòa” và “hoà”) được đưa về một dạng nhất thống.

Làm sạch văn bản chuyên sâu. Giai đoạn này tập trung loại bỏ các thành phần phi ngôn ngữ không đóng góp giá trị cho việc phân loại cảm xúc, bao gồm các thẻ định dạng HTML, biểu tượng cảm xúc (emoji), ký tự đặc biệt, đường dẫn liên kết (URL), địa chỉ email và số điện thoại.

Chuẩn hóa ngôn ngữ mạng và từ viết tắt. Đặc trưng của các bài đánh giá du lịch là sự xuất hiện dày đặc của từ lóng, teencode hoặc các cách viết tắt không thống nhất. Chúng tôi sử dụng một bộ từ

điển ánh xạ để chuyển đổi các biến thể này về ngôn ngữ tiêu chuẩn (ví dụ: các từ “ko”, “k”, “kh” được quy đổi về “không”). Cách tiếp cận này giúp khắc phục hiện tượng phân mảnh dữ liệu, đảm bảo các từ có cùng ý nghĩa được mô hình xử lý nhất quán.

Tách từ (Word Segmentation). Do tiếng Việt là ngôn ngữ đơn lập, ranh giới giữa các từ ghép thường không được phân tách rõ ràng bằng khoảng trắng như trong tiếng Anh. Chúng tôi sử dụng RDRSegmenter từ bộ VnCoreNLP để xác định ranh giới từ tiếng Việt (ví dụ: “nhân viên” được chuyển thành “nhân_viên”). Bước này đóng vai trò quyết định trong việc bảo toàn ngữ nghĩa của các thực thể và thuộc tính trong bài toán phân tích khía cạnh khách sạn.

Kết quả của toàn bộ pipeline là một tập dữ liệu sạch, có cấu trúc từ vựng đồng nhất và được phân đoạn rõ ràng, tạo tiền đề vững chắc cho giai đoạn trích xuất đặc trưng và huấn luyện các mô hình học máy.

4 Modeling

Để giải quyết bài toán Phân tích cảm xúc theo khía cạnh (ABSA) cho tiếng Việt, chúng tôi thiết lập một khung thực nghiệm toàn diện bao gồm ba hướng tiếp cận chính: (1) Học máy truyền thống dựa trên đặc trưng thống kê, (2) Học chuyển giao dựa trên đặc trưng (Feature-based Transfer Learning), và (3) Tinh chỉnh mô hình ngôn ngữ tiền huấn luyện (Fine-tuning Pre-trained Language Models). Tổng quan về các phương pháp được trình bày trong Hình 7.




Figure 7: Tổng quan các hướng tiếp cận mô hình hóa được thực nghiệm trong nghiên cứu.

4.1 Traditional Machine Learning

Đây là đường cơ sở (baseline) để đánh giá hiệu quả của các phương pháp hiện đại. Văn bản đầu vào được biểu diễn dưới dạng vector thưa (sparse vector) sử dụng kỹ thuật **TF-IDF** (Term Frequency-Inverse Document Frequency). Giá trị TF-IDF của một từ t trong văn bản d được tính toán nhằm phản

ánh tầm quan trọng của từ đó trong ngữ cảnh cụ thể, giảm trọng số của các từ xuất hiện quá phổ biến trong toàn bộ tập dữ liệu.

Trên không gian đặc trưng TF-IDF, chúng tôi triển khai bốn bộ phân lớp phổ biến:

- **Logistic Regression (LR):** Mô hình tuyến tính ước lượng xác suất $P(y|x)$ thông qua hàm Sigmoid. Chúng tôi sử dụng phương pháp tối ưu hóa Liblinear cho các bài toán văn bản thưa.
- **Support Vector Machine (SVM):** Tìm kiếm siêu phẳng (hyperplane) tối ưu $w^T x + b = 0$ để tối đa hóa lề (margin) giữa các lớp cảm xúc (Cortes and Vapnik, 1995).
- **Multinomial Naive Bayes (MNB):** Mô hình xác suất dựa trên định lý Bayes với giả định sự độc lập có điều kiện giữa các từ, thường cho hiệu quả cao trong phân loại văn bản cơ bản (McCallum and Nigam, 1998).
- **Random Forest (RF):** Một phương pháp học kết hợp (ensemble learning) xây dựng nhiều cây quyết định (Decision Trees) trong quá trình huấn luyện và đưa ra kết quả dựa trên cơ chế bỏ phiếu số đông (majority voting) (Breiman, 2001).

4.2 Feature-based Transfer Learning

Nhằm khắc phục hạn chế về sự thưa thớt và thiếu ngữ nghĩa của TF-IDF, chúng tôi áp dụng phương pháp Word Embedding để biểu diễn văn bản. Cụ thể, nghiên cứu sử dụng **PhoW2V** (Nguyen et al., 2020), một mô hình biểu diễn từ dày đặc (dense vector representation) chất lượng cao dành cho tiếng Việt.

PhoW2V được huấn luyện trên khối dữ liệu khổng lồ khoảng 20GB (bao gồm Wikipedia và dữ liệu báo chí tiếng Việt). Trong nghiên cứu này, chúng tôi sử dụng phiên bản vector có kích thước 100 chiều ($d = 100$). Một từ w (ví dụ: “nhân_viên”) sẽ được ánh xạ sang một vector thực $\mathbb{R}^{100}$ sao cho các từ có ngữ nghĩa tương đồng sẽ nằm gần nhau trong không gian vector.

Biểu diễn của toàn bộ câu review được tính bằng trung bình trọng số của các vector từ thành phần, sau đó được đưa vào các bộ phân lớp LR và SVM để dự đoán cảm xúc.

4.3 Fine-tuning Deep Learning Models

Phương pháp tiên tiến nhất được chúng tôi áp dụng là tinh chỉnh (fine-tuning) mô hình **PhoBERT**

(Nguyen and Nguyen, 2020). Đây là mô hình ngôn ngữ tiền huấn luyện (Pre-trained Language Model) đầu tiên dành riêng cho tiếng Việt, được xây dựng dựa trên kiến trúc RoBERTa (Liu et al., 2019) - một biến thể tối ưu hóa của BERT (Devlin et al., 2019).

4.3.1 Kiến trúc PhoBERT

Chúng tôi sử dụng phiên bản **PhoBERT-base** với các thông số kiến trúc như sau:

- **Transformer Encoder Layers:** 12 lớp.
- **Hidden Size:** 768 chiều.
- **Attention Heads:** 12 đầu.
- **Total Parameters:** 135 triệu tham số.

Mô hình sử dụng cơ chế chú ý (Self-Attention) đa đầu, cho phép nắm bắt ngữ cảnh hai chiều (bidirectional context) của từ trong câu, giải quyết tốt các vấn đề đa nghĩa trong tiếng Việt.

4.3.2 Chiến lược tinh chỉnh cho ABSA

Để áp dụng PhoBERT cho bài toán ABSA đa nhãn (xác định cảm xúc cho 34 cặp khía cạnh khác nhau), chúng tôi thiết kế kiến trúc đầu ra như mô tả trong Hình 8.




Figure 8: Kiến trúc PhoBERT được tinh chỉnh cho bài toán ABSA với 34 bộ phân lớp song song.

Quy trình xử lý như sau:

1. **Input Representation:** Câu review đầu vào X được thêm token đặc biệt '[CLS]' ở đầu và '[SEP]' ở cuối. Các từ được tách token bằng thuật toán Byte-Pair Encoding (BPE).
2. **Contextual Encoding:** Chuỗi đầu vào đi qua 12 lớp Encoder của PhoBERT. Vector đầu ra tương ứng với vị trí '[CLS]' ($h_{[CLS]} \in \mathbb{R}^{768}$) được coi là biểu diễn ngữ nghĩa tổng quát của toàn bộ câu review.
3. **Multi-head Classification:** Vector $h_{[CLS]}$ được đưa qua một lớp Dropout để tránh overfitting, sau đó đi vào 34 bộ phân lớp độc lập (classifiers). Mỗi bộ phân lớp i (tương ứng với một khía cạnh cụ

thể, ví dụ: *HOTEL#GENERAL*) là một lớp Linear kết hợp hàm Softmax để dự đoán xác suất phân bố trên 4 nhãn: $\{Positive, Negative, Neutral, None\}$.

Hàm mất mát (Loss function) được tính là tổng Cross-Entropy Loss của tất cả 34 bộ phân lớp, và mô hình được tối ưu hóa end-to-end thông qua lan truyền ngược (backpropagation).

5 Experiment & Result

5.1 Thiết lập thực nghiệm

Để đảm bảo tính khách quan và hiệu năng tối ưu cho các mô hình Machine Learning truyền thống (SVM, Logistic Regression, Random Forest, MultinomialNB), chúng tôi áp dụng quy trình tinh chỉnh siêu tham số (Hyperparameter Tuning) tự động. Cụ thể, framework **Optuna** (Akiba et al., 2019) được sử dụng với thuật toán Tree-structured Parzen Estimator (TPE) để tìm kiếm không gian tham số tối ưu.

Đối với mô hình Deep Learning (PhoBERT), chúng tôi sử dụng kiến trúc "phobert-base", kích thước batch là 16, learning rate $2e^{-5}$ và huấn luyện trong 30 epochs với chiến lược lưu vết (checkpointing) dựa trên độ đo F1-score trên tập Validation.

Độ đo chính được sử dụng để đánh giá là **Weighted F1-score**, phù hợp với bài toán phân loại đa nhãn có sự mất cân bằng dữ liệu giữa các lớp cảm xúc.

5.2 Results

Bảng 3 trình bày kết quả chi tiết của các phương pháp.

Approach	Feature	Model	F1-score	
			Val	Test
Machine Learning	TF-IDF	Logistic Regression	68.82	70.33
		Linear SVC	68.27	70.16
		Non-Linear SVC	64.47	65.95
		Multinomial NB	63.03	63.08
		Random Forest	67.23	68.78
	PhoW2V	Logistic Regression	63.63	65.25
		Linear SVC	64.11	64.32
		Non-Linear SVC	63.98	64.36
Deep Learning	Last hidden state	PhoBERT	72.29	73.83

Table 3: Kết quả thực nghiệm trên tập Validation và Test. Các giá trị cao nhất được in đậm.

5.3 Analysis & Discussion

Dựa trên kết quả thực nghiệm, chúng tôi rút ra ba quan sát quan trọng:

Thứ nhất, sự vượt trội của Mô hình Ngôn ngữ Tiền huấn luyện: PhoBERT đạt kết quả cao nhất với F1-score 73.83% trên tập Test, vượt xa các phương pháp truyền thống. Điều này khẳng định sức mạnh của kiến trúc Transformer và cơ chế Self-Attention trong việc nắm bắt ngữ cảnh hai chiều (bidirectional context). Khác với các mô hình ML chỉ dựa vào tần suất từ hoặc vector từ tĩnh, PhoBERT hiểu được sự đa nghĩa của từ trong các ngữ cảnh khác nhau của tiếng Việt, từ đó giải quyết tốt hơn các câu review phức tạp.

Thứ hai, hiệu quả của TF-IDF so với Word Embedding: Một kết quả đáng chú ý là các mô hình sử dụng đặc trưng truyền thống TF-IDF (đạt 70%) hoạt động hiệu quả hơn so với Word Embedding PhoW2V (đạt 65%). Chúng tôi lý giải điều này như sau:

- Các bài đánh giá khách sạn thường ngắn và chứa các từ khóa mang tính định danh cảm xúc cao (như "tệ", "tuyệt vời", "sạch sẽ"). TF-IDF rất mạnh trong việc gán trọng số cao cho các từ khóa này.
- PhoW2V là biểu diễn vector tĩnh (static embedding), việc lấy trung bình vector (averaging) cho cả câu có thể làm "phẳng" (smooth out) các tín hiệu cảm xúc quan trọng, dẫn đến việc mất mát thông tin trong các câu ngắn.

Thứ ba, hiệu năng của các bộ phân lớp tuyến tính: Trong nhóm Machine Learning, *Logistic Regression* và *Linear SVC* là hai thuật toán hoạt động ổn định và hiệu quả nhất (đều đạt trên 70% F1-score với TF-IDF). Điều này cho thấy với dữ liệu văn bản thưa (sparse data) và số lượng chiều cao như TF-IDF, các mô hình phân tích tuyến tính thường ít bị overfitting và tổng quát hóa tốt hơn so với các mô hình phi tuyến phức tạp như Non-Linear SVC hay Random Forest trong bối cảnh dữ liệu này.

6 Conclusion

Nghiên cứu đã xây dựng thành công quy trình và bộ dữ liệu gán nhãn chuẩn cho bài toán Phân tích cảm xúc theo khía cạnh (ABSA) trong lĩnh vực khách sạn tiếng Việt với độ đồng thuận cao (IAA 0.9551). Kết quả thực nghiệm khẳng định mô hình PhoBERT đạt hiệu suất vượt trội nhất (F1-score 73.83%), chứng minh khả năng nắm bắt ngữ cảnh

tốt hơn hẳn so với các phương pháp học máy truyền thống. Đáng chú ý, với đặc thù nhận xét ngắn, nghiên cứu chỉ ra rằng kỹ thuật TF-IDF vẫn mang lại hiệu quả cao hơn so với Word Embedding tĩnh (PhoW2V). Hướng phát triển trong tương lai sẽ tập trung vào việc xử lý mất cân bằng dữ liệu và tối ưu hóa mô hình cho các ứng dụng thực tế

References

References

- Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. 2019. *Optuna: A next-generation hyperparameter optimization framework*. In *KDD*, pages 2623–2631. ACM.
- Leo Breiman. 2001. *Random forests*. *Machine Learning*, 45(1):5–32.
- C. Cortes and V. Vapnik. 1995. Support vector networks. *Machine Learning*, 20:273–297.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. *Bert: Pre-training of deep bidirectional transformers for language understanding*. In *North American Chapter of the Association for Computational Linguistics*.
- Georgios Konstantinos, Jordan Clive, Georgia Harrison, Thomas Metcalfe, Patrycja Sliwiak, Hassan Tahir, and Aji Ghose. 2023. *Fabsa: An aspect-based sentiment analysis dataset of user reviews*. *Neurocomputing*, 562:126867.
- Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. *Roberta: A robustly optimized bert pretraining approach*. Cite arxiv:1907.11692.
- Andrew McCallum and Kamal Nigam. 1998. *A comparison of event models for naive Bayes text classification*. In *Learning for Text Categorization: Papers from the 1998 AAAI Workshop*, pages 41–48.
- Anh Tuan Nguyen, Mai Hoang Dao, and Dat Quoc Nguyen. 2020. A Pilot Study of Text-to-SQL Semantic Parsing for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 4079–4085.
- Dat Quoc Nguyen and Anh Tuan Nguyen. 2020. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042.